HidroPredict: sistema de predicción del nivel del río Paraguay mediante aprendizaje automático

Marcelo Gómez y Fabricio Paniagua

Ingeniería Informática · Universidad Católica Nuestra Señora de la Asunción · Paraguay

Resumen—Se presenta HidroPredict, un prototipo de pronóstico de niveles del río Paraguay en Concepción, Asunción y Villeta mediante aprendizaje automático supervisado. Integra observaciones hidrométricas paraguayas y brasileñas y variables meteorológicas históricas, con preprocesamiento, entrenamiento de modelos, API REST en FastAPI e interfaz React desplegable con Docker. Se examinan modelos de regresión y una evaluación retrospectiva de origen móvil en cinco fechas de 2026, para horizontes de 15 y 30 días. Los resultados muestran errores dependientes del puerto, horizonte y régimen hidrológico. En particular, una crecida rápida de octubre produjo subestimaciones importantes, mientras que los casos de septiembre resultaron más favorables. Se documentan limitaciones de calidad, incertidumbre y disponibilidad de variables futuras. El sistema constituye una demostración académica de ingeniería integral, no un servicio operativo de alerta hidrológica.

Palabras clave—aprendizaje automático, hidrología, Paraguay, predicción, series temporales.

I. INTRODUCCIÓN Y CONTEXTO

El río Paraguay influye en la navegación, la logística, la actividad económica y la gestión de riesgos del país. La anticipación de sus niveles es relevante para ciudades ribereñas como Concepción, Asunción y Villeta. Los métodos de aprendizaje automático permiten explorar relaciones no lineales entre cotas históricas, lluvia y temperatura, aunque su desempeño depende de la calidad y oportunidad de las observaciones [1]–[3].

El objetivo de HidroPredict es construir un sistema extremo a extremo, desde la integración de datos históricos hasta la consulta interactiva de pronósticos de uno a treinta días. La investigación se centra en la evaluación cuantitativa y en el comportamiento durante ascensos rápidos, sin asumir que se conocen precipitaciones posteriores a la emisión.

II. METODOLOGÍA Y ARQUITECTURA

A. Fuentes y preprocesamiento. La base maestra integra niveles diarios de la Dirección de Meteorología e Hidrología (DMH) en tres puertos paraguayos, niveles aguas arriba de estaciones brasileñas de la Agência Nacional de Águas e Saneamento Básico (ANA) y series de precipitación y temperatura de NASA POWER [1]–[3]. El periodo histórico de referencia abarca 2016–2025 y se dispone de observaciones de 2026 para evaluación y actualización. Se armonizan fechas, unidades, rezagos y variables meteorológicas acumuladas.

Se conservan registros de procedencia y ajustes. Un dato atípico de Porto Murtinho del 6 de octubre de 2026 (4,45 m) se sustituyó operativamente por una estimación de 2,45 m; el cambio está identificado y requiere corroboración independiente. La imputación y las revisiones posteriores pueden afectar una simulación retrospectiva.

B. Modelado. Se construyen variables de estacionalidad, niveles actuales y rezagados, cambios temporales, lluvia acumulada y temperatura media. Se emplean modelos supervisados de regresión, incluyendo Ridge y XGBoost, y se contrasta su desempeño con persistencia. Las predicciones directas se evalúan por puerto y horizonte; no se utilizan mediciones futuras como predictores.

C. Arquitectura. El servicio FastAPI expone predicciones y estado de datos mediante endpoints REST. La interfaz React/Vite permite seleccionar puerto y consultar curvas; Docker Compose inicia los servicios API y web. El repositorio mantiene código, modelos serializados, datos, resultados y documentación versionados [4].

III. RESULTADOS Y DISCUSIÓN

La métrica principal es el error absoluto medio (MAE), expresado en metros: $MAE = (1/n)\ \Sigma|y_i - \hat{y}_i|$. También resultan pertinentes RMSE y sesgo; las métricas de clasificación (accuracy, F1) no corresponden al problema de regresión.

La Tabla I presenta el backtesting experimental de origen móvil de la Fase 18: cinco fechas de 2026 (febrero, abril, junio, agosto y octubre), tres puertos y horizontes de 15 y 30 días. En cada origen se reentrenaron candidatos utilizando únicamente objetivos observables hasta esa fecha. Cada celda resume cinco predicciones, por lo que los resultados son exploratorios y no estimaciones definitivas de rendimiento [4].

TABLA I. MAE EN BACKTESTING EXPERIMENTAL (m)

Puerto / días	Persist.	Ridge	XGB
Concepción / 15	0,392	0,324	0,360
Concepción / 30	0,518	0,091	0,361
Asunción / 15	0,572	0,446	0,457
Asunción / 30	0,964	0,710	0,677
Villeta / 15	0,566	0,519	0,525
Villeta / 30	1,032	0,807	0,726

Ridge registra el menor MAE en cuatro combinaciones y XGBoost en dos. Esta elección se realiza a posteriori para describir la muestra; no equivale a validar un selector automático ni demuestra que los modelos experimentales superen a los desplegados en producción.

La Tabla II contrasta dos orígenes concretos: el 1 de septiembre y el 1 de octubre de 2026, con XGBoost regularizado a 30 días. Son errores de predicciones puntuales, no MAE mensuales ni métricas de la API operativa [5].

TABLA II. ERROR ABSOLUTO A 30 DÍAS (m)

Puerto	01/09	01/10
Concepción	0,067	0,434
Asunción	0,269	1,343
Villeta	0,144	1,684

En Asunción, el nivel pasó de 0,50 m el 1 de octubre a 2,76 m el 31 de octubre; XGBoost predijo 1,417 m para la segunda fecha, con subestimación de 1,343 m. En Villeta el error equivalente alcanzó 1,684 m. El modelo no conocía al emitir el pronóstico las lluvias intensas de los días posteriores [5].

La serie NASA POWER de Concepción acumula aproximadamente 6,7 mm entre el 1 y 12 de septiembre frente a 131,8 mm en el mismo intervalo de octubre. Esto es consistente con una respuesta hidrológica a precipitaciones intensas, pero no establece causalidad única; los aportes de tributarios, la humedad antecedente y el transporte de ondas de crecida requieren análisis adicional [3], [5].

El estudio detectó además posibles redundancias de celdas meteorológicas, correcciones manuales no verificadas y una cobertura incierta de los intervalos predictivos. Las observaciones revisadas después del origen pueden impedir que el backtesting reproduzca exactamente la disponibilidad de datos de un pronóstico real. Por ello se diferencia el experimento de los modelos actualmente consumidos por la API.

IV. CONCLUSIONES Y TRABAJO FUTURO

HidroPredict integra un conjunto histórico contextualizado en Paraguay, modelos de regresión, API REST, interfaz interactiva y despliegue mediante contenedores. Los experimentos muestran capacidad de aproximar niveles en ciertos periodos, pero dificultades significativas para anticipar crecidas rápidas, especialmente en octubre de 2026. No se ha demostrado una mejora general que justifique reemplazar los modelos operativos.

Como trabajo futuro se propone ampliar la validación temporal y por episodios, contrastar observaciones sospechosas con fuentes independientes, mejorar la cobertura espacial de lluvias y estudiar humedad del suelo y caudales tributarios. Los pronósticos meteorológicos futuros archivados por fecha de emisión podrían aumentar la anticipación de crecidas, hipótesis que exige evaluación sin fuga de información. El uso de ENSO o represas requiere evidencia hidrológica y series históricas apropiadas.

REFERENCIAS

[1] Dirección de Meteorología e Hidrología (DMH), “Nivel del río Paraguay: registros hidrométricos”, Paraguay. [En línea]. Disponible: https://www.meteorologia.gov.py/nivel-rio/.

[2] Agência Nacional de Águas e Saneamento Básico (ANA), “Sistema de Informações Hidrológicas”, Brasil. [En línea]. Disponible: https://www.snirh.gov.br/hidroweb/.

[3] NASA, “POWER Data Access Viewer”, Prediction Of Worldwide Energy Resources. [En línea]. Disponible: https://power.larc.nasa.gov/.

[4] M. Gómez y F. Paniagua, “HidroPredict: Fase 18—Backtesting de origen móvil”, informe técnico del proyecto, 2026. Repositorio: https://github.com/FabriPaniagua/IA.

[5] M. Gómez y F. Paniagua, “HidroPredict: auditoría hidrológica y contraste septiembre/octubre de 2026”, informe técnico del proyecto, 2026. Repositorio: https://github.com/FabriPaniagua/IA.

[6] T. Chen y C. Guestrin, “XGBoost: A scalable tree boosting system”, en Proc. 22nd ACM SIGKDD, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.

[7] A. E. Hoerl y R. W. Kennard, “Ridge regression: Biased estimation for nonorthogonal problems”, Technometrics, vol. 12, no. 1, pp. 55–67, 1970, doi: 10.1080/00401706.1970.10488634.

DISPONIBILIDAD Y REPRODUCIBILIDAD

El código fuente, las instrucciones de despliegue, los modelos serializados y los registros de experimentación se mantienen en el repositorio del proyecto [4]. La aplicación puede iniciarse mediante docker compose up -d --build. La interfaz se publica localmente en el puerto 8080 y la documentación de la API en el puerto 8000.

Los resultados de las Tablas I y II proceden de los archivos CSV de las investigaciones Fases 18 y 19, respectivamente. El backtesting utiliza orígenes retrospectivos y no debe confundirse con la evaluación prospectiva del servicio desplegado.

Declaración de alcance: prototipo académico para investigación y demostración; sus predicciones no sustituyen boletines oficiales ni son aptas, sin validación adicional, para decisiones de navegación o gestión de emergencias.